

Autosimilarité multivariée : estimation des exposants d'autosimilarité, tests bootstrap d'égalité des exposants et applications

Charles-Gérard Lucas
Soutenance de thèse
19 octobre 2023


Patrice Abry CNRS, Laboratoire de Physique, ENS de Lyon
Herwig Wendt CNRS, IRIT, Université de Toulouse
Gustavo Didier Université Tulane, Nouvelle-Orléans, USA




Invariance d'échelle





Invariance d'échelle



Invariance d'échelle



Invariance d'échelle




Invariance d'échelle dans le monde réel


Cours de la bourse



Activité cérébrale




Traffic internet




Source: freepik.com

Stylométrie



Autosimilarité : définition



$$\{\mathcal{B}_H(t)\}_{t \in \mathbb{R}} \stackrel{fdd}{=} \left\{ a^H \mathcal{B}_H(t/a) \right\}_{t \in \mathbb{R}}, \quad \forall a > 0$$

→ paramètre d'autosimilarité $0 < H < 1$

Objectif : Estimation de H à partir d'un signal de taille finie (N)

Autosimilarité : modèle

Mouvement brownien fractionnaire


Définition

Processus gaussien \mathcal{B}_H autosimilaire de paramètre H

- Loi : $\mathcal{B}_H(t) \sim \mathcal{N}(0, \sigma_t^2)$, $\mathcal{B}_H(0) = 0$
- Variance : $\sigma_t^2 = \mathbb{E}[\mathcal{B}_H(t)\mathcal{B}_H(t)] = C_H|t|^{2H}$
- Accroissements stationnaires

→ Fonction de covariance :


$$\mathbb{E}[\mathcal{B}_H(t)\mathcal{B}_H(s)] = \frac{C_H}{2} \left(|t|^{2H} + |s|^{2H} - |t-s|^{2H} \right)$$

→ Rugosité (Hölder) $h = H$ 

Autosimilarité : analyse

Transformée en ondelettes

$$D(2^j, k) = \langle \psi_{j,k} | \mathcal{B}_H \rangle$$



$$\psi_{j,k}(t) = 2^{-j/2} \psi_0(2^{-j}t - k)$$

↳ ondelette mère ψ_0 traduite et dilatée

Spectre d'ondelettes

Variance à l'échelle 2^j


$$S(2^j) = \frac{1}{n_j} \sum_{k=1}^{n_j} D(2^j, k)^2$$

$n_j = N/2^j$, N : taille d'échantillon

Autosimilarité : analyse

Transformée en ondelettes

$$D(2^j, k) = \langle \psi_{j,k} | \mathcal{B}_H \rangle$$



Spectre d'ondelettes

Variance à l'échelle 2^j

$$S(2^j) = \frac{1}{n_j} \sum_{k=1}^{n_j} D(2^j, k)^2$$


 $n_j = N/2^j$, N : taille d'échantillon

\mathcal{B}_H autosimilaire
 \Rightarrow loi de puissance : $S(2^j) \propto (2^j)^{(2H+1)}$
[Flaardin, 1992]

→ Régression linéaire en log-log



$$\hat{H} = \frac{1}{2} \sum_{j=j_1}^{j_2} \omega_j \log_2 S(2^j) - \frac{1}{2}$$

[Abry et Veitch, 1998]



Données multivariées

Collection de signaux décrivant un même système



- M analyses univariées ?
- 1 analyse multivariée ?

Gliederung

① Introduction

② Modélisation

③ Estimation


④ Dénombrement et regroupement

⑤ Application biomédicale

Autosimilarité multivariée : extension naturelle

Collection de M mouvements browniens fractionnaires corrélés

[Mason et Xiao, 2002; Amblard et Cœurjolly, 2011]



- Modélisation : $\underline{H} = (H_1, \dots, H_M)$, Σ
- M relations d'autosimilarité univariées :

$$\{(\mathcal{B}_{\underline{H}, \Sigma}(t))_m\}_{t \in \mathbb{R}} \stackrel{fdd}{=} \{a^{H_m} (\mathcal{B}_{\underline{H}, \Sigma}(t/a))_m\}_{t \in \mathbb{R}}, \quad \forall a > 0$$

Autosimilarité multivariée : extension naturelle

Collection de M mouvements browniens fractionnaires corrélés

[Mason et Xiao, 2002; Amblard et Cœurjolly, 2011]

$$\begin{array}{c}
 \text{Matrice de mélange } W = \mathbb{I} \quad \times \quad \mathcal{B}_{\underline{H}, \Sigma}(t) \quad = \quad \mathcal{B}_{\underline{H}, \Sigma, W}(t) \\
 \hline
 \left[\begin{array}{cccc}
 1 & 0 & \cdots & 0 \\
 0 & 1 & \cdots & 0 \\
 \vdots & \vdots & \ddots & \vdots \\
 0 & 0 & \cdots & 1
 \end{array} \right] \quad \Sigma \quad \left[\begin{array}{c}
 \begin{array}{c} \text{Matrice de covariance} \end{array} \\
 \begin{array}{c} \text{---} \\ \vdots \\ \text{---} \end{array}
 \end{array} \right] \quad \left[\begin{array}{c}
 \begin{array}{c} \text{---} \\ \vdots \\ \text{---} \end{array} \\
 \begin{array}{c} \text{---} \\ \vdots \\ \text{---} \end{array}
 \end{array} \right] \quad \left[\begin{array}{c}
 \begin{array}{c} \text{---} \\ \vdots \\ \text{---} \end{array} \\
 \begin{array}{c} \text{---} \\ \vdots \\ \text{---} \end{array}
 \end{array} \right]
 \end{array}$$

- Modélisation : $\underline{H} = (H_1, \dots, H_M)$, Σ , $W = \mathbb{I}$
- M relations d'autosimilarité univariées :

$$\{(\mathcal{B}_{\underline{H}, \Sigma}(t))_m\}_{t \in \mathbb{R}} \stackrel{fdd}{=} \{\mathbf{a}^{\underline{H}_m} (\mathcal{B}_{\underline{H}, \Sigma}(t/\mathbf{a}))_m\}_{t \in \mathbb{R}}, \quad \forall \mathbf{a} > 0$$

Autosimilarité multivariée : modèle

Mouvement brownien fractionnaire multivarié

[Abry et al., 2019]

$$\begin{array}{c}
 \text{Matrice de mélange } W \quad \times \quad \mathcal{B}_{\underline{H}, \Sigma}(t) \quad = \quad \mathcal{B}_{\underline{H}, \Sigma, W}(t) \\
 \hline
 \begin{bmatrix} W_{1,1} & W_{1,2} & \cdots & W_{1,M} \\ W_{2,1} & W_{2,2} & \cdots & W_{2,M} \\ \vdots & \vdots & \ddots & \vdots \\ W_{M,1} & W_{M,2} & \cdots & W_{M,M} \end{bmatrix} \quad \Sigma \quad \begin{bmatrix} \text{Matrice de covariance} \\ \vdots \\ \Sigma \end{bmatrix} \quad \begin{bmatrix} \text{H}_1 \\ \vdots \\ \text{H}_M \end{bmatrix} \quad \begin{bmatrix} \text{H}_1 \\ \vdots \\ \text{H}_M \end{bmatrix} \quad \begin{bmatrix} \text{H}_1 \\ \vdots \\ \text{H}_M \end{bmatrix}
 \end{array}$$

- Modélisation : $\underline{H} = (\text{H}_1, \dots, \text{H}_M)$, Σ , W réelle et inversible
- Relation d'autosimilarité multivariée :

$$\{\mathcal{B}_{\underline{H}, \Sigma, W}(t)\}_{t \in \mathbb{R}} \stackrel{fdd}{=} \left\{ \textcolor{red}{a}^{\underline{H}} \mathcal{B}_{\underline{H}, \Sigma, W}(t/\textcolor{red}{a}) \right\}_{t \in \mathbb{R}}, \quad \forall \textcolor{red}{a} > 0$$

$$\textcolor{red}{a}^{\underline{H}} = \sum_{k \geq 0} \frac{1}{k!} \log^k \textcolor{red}{a} \underline{H}^k, \quad \underline{H} = W \text{diag}(\underline{H}) W^{-1}$$

Autosimilarité multivariée : modèle

Mouvement brownien opérateur-fractionnaire [Didier et Pipiras, 2011]

$$\mathcal{B}_{\underline{\underline{H}},A}(t) = \int_{\mathbb{R}} \frac{e^{itf} - 1}{if} \left(f_+^{-\left(\underline{\underline{H}} - \frac{1}{2}\mathbb{I}\right)} A + f_-^{-\left(\underline{\underline{H}} - \frac{1}{2}\mathbb{I}\right)} \bar{A} \right) \tilde{B}(df)$$


- $f \in \mathbb{R}$, $\mathbb{E}[\tilde{B}(df)\tilde{B}(df)^*] = df$
- $\underline{\underline{H}}$: matrice complexe de taille $M \times M$
- A : matrice complexe de taille $M \times M$, $\det AA^* > 0$

Mouvement brownien fractionnaire multivarié

$$\mathcal{B}_{\underline{\underline{H}},\Sigma,W} = \mathcal{B}_{\underline{\underline{H}},A} \quad \text{avec} \quad \begin{cases} \underline{\underline{H}} = W \text{ diag}(\underline{\underline{H}}) W^{-1} \\ AA^* = W (G \odot \Sigma) W^\top \end{cases}$$

- $G_{m,m'} = \frac{1}{2\pi} \Gamma(H_m + H_{m'} + 1) \sin((H_m + H_{m'}) \frac{\pi}{2})$
- $\det AA^* > 0 \Rightarrow \det G \odot \Sigma > 0$

[Lucas et al., 2023a]



Gliederung

① Introduction

② Modélisation


③ Estimation

④ Dénombrement et regroupement

⑤ Application biomédicale

Autosimilarité multivariée : analyse

Transformée en ondelettes multivariée
 $D(2^j, k) = (D_1(2^j, k), \dots, D_M(2^j, k))$



Spectre d'ondelettes


Covariance à l'échelle 2^j

$$S(2^j) = \begin{bmatrix} S_{1,1}(2^j) & \cdots & S_{1,M}(2^j) \\ \vdots & \ddots & \vdots \\ S_{M,M}(2^j) & \cdots & S_{M,1}(2^j) \end{bmatrix}$$

$$S_{m,m'}(2^j) = \frac{1}{n_j} \sum_{k=1}^{n_j} D_m(2^j, k) D_{m'}(2^j, k)$$

Autosimilarité multivariée : analyse

Transformée en ondelettes multivariée
 $D(2^j, k) = (D_1(2^j, k), \dots, D_M(2^j, k))$



Spectre d'ondelettes

Covariance à l'échelle 2^j

$$S(2^j) = \begin{bmatrix} S_{1,1}(2^j) & \cdots & S_{1,M}(2^j) \\ \vdots & \ddots & \vdots \\ S_{M,M}(2^j) & \cdots & S_{M,1}(2^j) \end{bmatrix}$$


$$S_{m,m'}(2^j) = \frac{1}{n_j} \sum_{k=1}^{n_j} D_m(2^j, k) D_{m'}(2^j, k)$$

Cas $W = \mathbb{I}$ [Wendt et al., 2018]

$\mathcal{B}_{H,\Sigma,W}$ autosimilaire
 \Rightarrow loi de puissance :
 $S_{m,m'}(2^j) \propto (2^j)^{(H_m + H_{m'} + 1)}$


→ Régression linéaire en log-log

$$\hat{H}_{m,m'} = \frac{1}{2} \sum_{j=j_1}^{j_2} \omega_j \log_2 S_{m,m'}(2^j) - \frac{1}{2}$$



Autosimilarité multivariée : analyse

Transformée en ondelettes multivariée
 $D(2^j, k) = (D_1(2^j, k), \dots, D_M(2^j, k))$



Spectre d'ondelettes

Covariance à l'échelle 2^j

$$S(2^j) = \begin{bmatrix} S_{1,1}(2^j) & \cdots & S_{1,M}(2^j) \\ \vdots & \ddots & \vdots \\ S_{M,M}(2^j) & \cdots & S_{M,1}(2^j) \end{bmatrix}$$


$$S_{m,m'}(2^j) = \frac{1}{n_j} \sum_{k=1}^{n_j} D_m(2^j, k) D_{m'}(2^j, k)$$

Cas $W = \mathbb{I}$ [Wendt et al., 2018]

$\mathcal{B}_{H, \Sigma, W}$ autosimilaire
 \Rightarrow loi de puissance :
 $S_{m,m}(2^j) \propto (2^j)^{(2H_m + 1)}$


→ Régression linéaire en log-log

$$\hat{H}_m^U = \frac{1}{2} \sum_{j=j_1}^{j_2} \omega_j \log_2 S_{m,m}(2^j) - \frac{1}{2}$$



Autosimilarité multivariée : analyse

Transformée en ondelettes multivariée
 $D(2^j, k) = (D_1(2^j, k), \dots, D_M(2^j, k))$



Spectre d'ondelettes

Covariance à l'échelle 2^j

$$S(2^j) = \begin{bmatrix} S_{1,1}(2^j) & \cdots & S_{1,M}(2^j) \\ \vdots & \ddots & \vdots \\ S_{M,M}(2^j) & \cdots & S_{M,1}(2^j) \end{bmatrix}$$

$$S_{m,m'}(2^j) = \frac{1}{n_j} \sum_{k=1}^{n_j} D_m(2^j, k) D_{m'}(2^j, k)$$

Cas $W \neq \mathbb{I}$ [Wendt et al., 2018]


$\mathcal{B}_{H,\Sigma,W}$ autosimilaire avec $W \neq \mathbb{I}$

⇒ mélange de M^2 lois de puissance :

$$S_{m,m'}(2^j) = \sum_{k,n} \alpha_{k,n}^{(m,m')}(2^j)^{(H_k + H_n + 1)}$$

→ Régression linéaire en log-log

$$\hat{H}_m^U = \frac{1}{2} \sum_{j=j_1}^{j_2} \omega_j \log_2 S_{m,m}(2^j) - \frac{1}{2}$$



Autosimilarité multivariée : analyse

Décomposition spectrale:


$$S(2^j) = U(2^j) \begin{bmatrix} \hat{\lambda}_1(2^j) & 0 & \cdots & \cdots & 0 \\ 0 & \hat{\lambda}_2(2^j) & \cdots & \cdots & 0 \\ 0 & 0 & \ddots & & \vdots \\ \vdots & \vdots & & \ddots & 0 \\ 0 & 0 & \cdots & 0 & \hat{\lambda}_M(2^j) \end{bmatrix} U(2^j)^{-1}$$

Estimation multivariée [Abry et Didier, 2018a; 2018b]

$\mathcal{B}_{H, \Sigma, W}$ autosimilaire
 \Rightarrow loi de puissance asymptotique :
 $\hat{\lambda}_m(2^j) \underset{j \rightarrow +\infty}{\propto} (2^j)^{(2H_m + 1)}$

\rightarrow Régression linéaire en log-log



$$\hat{H}_m^M = \frac{1}{2} \sum_{j=j_1}^{j_2} \omega_j \log_2 \hat{\lambda}_m(2^j) - \frac{1}{2}$$



Biais de répulsion

Nombre fini n_j de coefficients d'ondelettes disponibles

$\Rightarrow \hat{\lambda}_m(2^j) - \hat{\lambda}_{m'}(2^j) \gg \lambda_m(2^j) - \lambda_{m'}(2^j)$ pour $H_m = H_{m'}$ [Tao, 2012]





- ⚠ Nombre n_j de coefficients d'ondelettes disponibles varie avec 2^j
 \Rightarrow écart $\hat{\lambda}_{m'}(2^j) - \hat{\lambda}_m(2^j)$ croissant avec 2^j
 \Rightarrow biais dans les régressions linéaires

Correction de l'estimation

- Ré-échantillonnage par bloc bootstrap temps-échelle [Wendt et al., 2019]
- Reproduction du biais au travers des échelles :

$$\rightarrow S^{(w)}(2^j) = \frac{1}{n_{j_2}} \sum_{k \in F_w} D(2^j, k) D(2^j, k)^\top$$

$$\text{Card}(F_w) = n_{j_2}, \quad w = 1, \dots, 2^{j_2-j}$$




- Valeurs propres $\hat{\lambda}_1^{(w)}(2^j), \dots, \hat{\lambda}_M^{(w)}(2^j)$ de $S^{(w)}(2^j)$
 $\downarrow \hat{\lambda}_{m'}^{(w)}(2^j) - \hat{\lambda}_m^{(w)}(2^j)$ similaires à toutes les échelles 2^j
- Moyenne des logarithmes : $\log_2 \bar{\lambda}_m(2^j) = \langle \log_2 \hat{\lambda}_m^{(w)}(2^j) \rangle_w$

$$\rightarrow \text{Régression linéaire : } \hat{H}_m^{\text{M, bc}} = \frac{1}{2} \sum_{j=j_1}^{j_2} \omega_j \log_2 \bar{\lambda}_m(2^j) - \frac{1}{2}$$

Correction du biais de répulsion

Estimation non corrigée contre estimation corrigée



Étude des performances asymptotiques théoriques

Cadre asymptotique

Double limite :

- $N \rightarrow +\infty$
- $2^{j_1}, \dots, 2^{j_2} \rightarrow +\infty$

Vitesse de convergence des $2^{j_1}, \dots, 2^{j_2}$:

$$j_1 = j_1^0 + \log_2 a(N)$$

⋮

$$j_2 = j_2^0 + \log_2 a(N)$$

avec

- $a(N) \sim N^\beta, \quad 1/(2\varpi + 1) < \beta < 1$
- $\varpi = \min \left\{ \min_{\{2 \leq i \leq M \mid H_i - H_{i-1} > 0\}} (H_i - H_{i-1}), \frac{H_1}{2} + \frac{1}{4} \right\}$

[Abry et al., 2018a; 2018b]

Étude des performances asymptotiques théoriques

Consistance

Pour $\mathcal{B}_{\underline{H}, \Sigma, W}$,

$$\hat{\underline{H}}^U \rightarrow \underline{H} \text{ si } W = \mathbb{I}$$

[Wendt et al., 2018]

$$\hat{\underline{H}}^M \rightarrow \underline{H}$$

[Abry et Didier, 2018a; 2018b]

$$\hat{\underline{H}}^{M, bc} \rightarrow \underline{H}$$

[Lucas et al., 2023a]

Étude des performances asymptotiques théoriques

Consistance

Pour $\mathcal{B}_{\underline{H}, \Sigma, W}$,

$$\hat{\underline{H}}^U \rightarrow \underline{H} \text{ si } W = \mathbb{I}$$

[Wendt et al., 2018]

$$\hat{\underline{H}}^M \rightarrow \underline{H}$$

[Abry et Didier, 2018a; 2018b]

$$\hat{\underline{H}}^{M, bc} \rightarrow \underline{H}$$

[Lucas et al., 2023a]

Normalité asymptotique

Pour $\mathcal{B}_{\underline{H}, \Sigma, W}$, si $\lambda_1(a(N)2^j) \neq \dots \neq \lambda_M(a(N)2^j)$ lorsque $N \rightarrow +\infty$, alors

$$\sqrt{\frac{a(N)}{N}} \left(\hat{\underline{H}}^{M, bc} - \underline{H} \right) \rightarrow \mathcal{N}(\mathbf{0}, \Sigma_B)$$

[Lucas et al., 2023a]

Étude des performances asymptotiques théoriques

Consistance

Pour $\mathcal{B}_{\underline{H}, \Sigma, W}$,

$$\hat{\underline{H}}^U \rightarrow \underline{H} \text{ si } W = \mathbb{I}$$

[Wendt et al., 2018]

$$\hat{\underline{H}}^M \rightarrow \underline{H}$$

[Abry et Didier, 2018a; 2018b]

$$\hat{\underline{H}}^{M, bc} \rightarrow \underline{H}$$

[Lucas et al., 2023a]

Normalité asymptotique

Pour $\mathcal{B}_{\underline{H}, \Sigma, W}$, si $\lambda_1(a(N)2^j) \neq \dots \neq \lambda_M(a(N)2^j)$ lorsque $N \rightarrow +\infty$, alors

$$\sqrt{\frac{a(N)}{N}} \left(\hat{\underline{H}}^{M, bc} - \underline{H} \right) \rightarrow \mathcal{N}(\mathbf{0}, \Sigma_B)$$

[Lucas et al., 2023a]

- Effets de taille finie ?
- Impact des paramètres \underline{H} , Σ et W sur la corrélation Σ_B ?

Étude des performances empirique de taille finie

Simulations : 1000 réalisations, $M = 6$ composantes

- Tailles d'échantillon $N \in \{2^{13}, \dots, 2^{18}\}$
- $2^{j_1} = a(N)2^6, \dots, 2^{j_2} = a(N)2^9$ with $a(N) = 2^{\lfloor 0.9 \log_2 N/2^{13} \rfloor}$
- $\Sigma = \Sigma_0$
- 4 configurations :
 - $W \neq \mathbb{I}$ et $H_1 \neq \dots \neq H_M$
 - $W \neq \mathbb{I}$ et $H_1 = \dots = H_M$
 - $W = \mathbb{I}$ et $H_1 \neq \dots \neq H_M$
 - $W = \mathbb{I}$ et $H_1 = \dots = H_M$


Mesures de performance des estimateurs \hat{H} :

- sBias = $(\mathbb{E}\hat{H} - \underline{H})(\mathbb{E}\hat{H} - \underline{H})^\top$
 - Cov = $\mathbb{E}[(\mathbb{E}\hat{H} - \hat{H})(\mathbb{E}\hat{H} - \hat{H})^\top]$
 - $MSE = \mathbb{E}[(\hat{H} - \underline{H})(\hat{H} - \underline{H})^\top] = \text{sBias} + \text{Cov}$
(erreur quadratique moyenne)
- norme spectrale $\|\cdot\|_2$

Distribution normale multivariée de $\hat{H}^{M, bc}$

Diagramme quantile-quantile :

$$\left(\hat{H}^{M, bc} - \mathbb{E}\hat{H}^{M, bc} \right) \text{Cov} \left(\hat{H}^{M, bc} \right)^{-1} \left(\hat{H}^{M, bc} - \mathbb{E}\hat{H}^{M, bc} \right)^\top$$


contre distribution du χ^2 à M degrés de liberté→ Normalité multivariée approximative de $\hat{H}^{M, bc}$, même à faible N

Performances d'estimation comparées

$$W \neq \mathbb{I}$$

$$H_1 \neq \dots \neq H_M$$

+ estimation univariée $\underline{\hat{H}}^U$
 Δ estimation multivariée $\underline{\hat{H}}^M$
 o estimation multivariée corrigée $\underline{\hat{H}}^{M,bc}$



→ $\underline{\hat{H}}^U$ biaisé par le paramètre dominant H_M

→ performances similaires entre $\underline{\hat{H}}^M$ et $\underline{\hat{H}}^{M,bc}$


$$\underline{\hat{H}}^{M,bc} \sim \underline{\hat{H}}^M \gg \underline{\hat{H}}^U$$

Performances d'estimation comparées

$$W \neq \mathbb{I}$$

$$H_1 = \dots = H_M$$

- + estimation univariée $\underline{\hat{H}}^U$
- Δ estimation multivariée $\underline{\hat{H}}^M$
- o estimation multivariée corrigée $\underline{\hat{H}}^{M,bc}$



→ $\underline{\hat{H}}^U$ moins biaisé que $\underline{\hat{H}}^M$ car $H_1 = \dots = H_M$

→ $\underline{\hat{H}}^{M,bc}$ meilleur que $\underline{\hat{H}}^M$: correction du biais de répulsion


$$\underline{\hat{H}}^{M,bc} \geq \underline{\hat{H}}^M \sim \underline{\hat{H}}^U$$

Performances d'estimation comparées

$$W = \mathbb{I}$$

$$H_1 \neq \dots \neq H_M$$

- + estimation univariée \hat{H}^U
- Δ estimation multivariée \hat{H}^M
- o estimation multivariée corrigée $\hat{H}^{M,bc}$



- performances de \hat{H}^M et $\hat{H}^{M,bc}$ similaires au cas $W \neq \mathbb{I}$
- compromis biais-covariance entre estimations univariée et multivariées


$$\hat{H}^{M,bc} \sim \hat{H}^M \sim \hat{H}^U$$

Performances d'estimation comparées

$$W = \mathbb{I}$$

$$H_1 = \dots = H_M$$

- + estimation univariée \hat{H}^U
- Δ estimation multivariée \hat{H}^M
- o estimation multivariée corrigée $\hat{H}^{M,bc}$



→ \hat{H}^U moins biaisé que \hat{H}^M car $H_1 = \dots = H_M$

→ $\hat{H}^{M,bc}$ meilleur que \hat{H}^M : correction du biais de répulsion

⇒ similaire au cas $W \neq \mathbb{I}$ et $H_1 = \dots = H_M$

$$\hat{H}^{M,bc} \geq \hat{H}^M \sim \hat{H}^U$$

Synthèse des performances d'estimation

$$\boxed{\begin{array}{l} W \neq \mathbb{I} \\ H_1 \neq \dots \neq H_M \end{array}} \Rightarrow \hat{H}^{\text{M,bc}} \sim \hat{H}^{\text{M}} \gg \hat{H}^{\text{U}}$$

$$\boxed{\begin{array}{l} W \neq \mathbb{I} \\ H_1 = \dots = H_M \end{array}} \Rightarrow \hat{H}^{\text{M,bc}} \geq \hat{H}^{\text{M}} \sim \hat{H}^{\text{U}}$$

$$\boxed{\begin{array}{l} W = \mathbb{I} \\ H_1 \neq \dots \neq H_M \end{array}} \Rightarrow \hat{H}^{\text{M,bc}} \sim \hat{H}^{\text{M}} \sim \hat{H}^{\text{U}}$$

$$\boxed{\begin{array}{l} W = \mathbb{I} \\ H_1 = \dots = H_M \end{array}} \Rightarrow \hat{H}^{\text{M,bc}} \geq \hat{H}^{\text{M}} \sim \hat{H}^{\text{U}}$$


$\hat{H}^{\text{M,bc}}$ peut être utilisé dans toutes les configurations

Corrélation des estimateurs

$$W \neq \mathbb{I}$$

$$H_1 \neq \dots \neq H_M$$

- + estimation univariée \hat{H}^U
- Δ estimation multivariée \hat{H}^M
- estimation multivariée corrigée $\hat{H}^{M, bc}$




→ Quasi-décorrélation de $\hat{H}^{M, bc}$ et \hat{H}^M , même pour N faible

Corrélation des estimateurs

$$W = \mathbb{I}$$

$$H_1 \neq \dots \neq H_M$$

- + estimation univariée \hat{H}^U
- Δ estimation multivariée \hat{H}^M
- estimation multivariée corrigée $\hat{H}^{M, bc}$



→ Quasi-décorrélation de $\hat{H}^{M, bc}$ et \hat{H}^M , même pour N faible

Gliederung

① Introduction

② Modélisation

③ Estimation

④ Dénombrement et regroupement

⑤ Application biomédicale

Tests d'égalité

Fluctuation de l'estimation : $\hat{H}_m \neq \hat{H}_{m'}$ même si $H_m = H_{m'}$

Problème :

- Combien de paramètres distincts dans $\underline{H} = (H_1, \dots, H_M)$?
- Combien de paramètres H_m prennent chacune de ces valeurs ?

Tests d'égalité

Fluctuation de l'estimation : $\hat{H}_m \neq \hat{H}_{m'}$ même si $H_m = H_{m'}$

Problème :

- Combien de paramètres distincts dans $\underline{H} = (H_1, \dots, H_M)$?
- Combien de paramètres H_m prennent chacune de ces valeurs ?

Solutions :

- Tester $H_1 = \dots = H_M$ [Lucas et al., EUSIPCO, 2021]

Tests d'égalité


Fluctuation de l'estimation : $\hat{H}_m \neq \hat{H}_{m'}$ même si $H_m = H_{m'}$

Problème :

- Combien de paramètres distincts dans $\underline{H} = (H_1, \dots, H_M)$?
- Combien de paramètres H_m prennent chacune de ces valeurs ?

Solutions :

- Tester $H_1 = \dots = H_M$ [Lucas et al., EUSIPCO, 2021]
- Trier $\hat{H}_{\tau(1)} \leq \dots \leq \hat{H}_{\tau(M)} \Rightarrow M - 1$ tests pour $H_m = H_{m+1}$ [Lucas et al., ICASSP, 2022; Lucas et al., GRETSI, 2022]



Tests d'égalité


Fluctuation de l'estimation : $\hat{H}_m \neq \hat{H}_{m'}$ même si $H_m = H_{m'}$

Problème :


- Combien de paramètres distincts dans $\underline{H} = (H_1, \dots, H_M)$?
- Combien de paramètres H_m prennent chacune de ces valeurs ?

Solutions :

- Tester $H_1 = \dots = H_M$ [Lucas et al., EUSIPCO, 2021]
- Trier $\hat{H}_{\tau(1)} \leq \dots \leq \hat{H}_{\tau(M)} \Rightarrow M - 1$ tests pour $H_m = H_{m+1}$ [Lucas et al., ICASSP, 2022; Lucas et al., GRETSI, 2022]



- $M(M - 1)/2$ tests pour $H_m = H_{m'}, m \neq m'$ [Lucas et al., 2023]



Test pour $H_m = H_{m'}$

• Formulation :

- $M(M - 1)/2$ hypothèses : $H_m = H_{m'}$, $1 \leq m < m' \leq M$
- Estimées multivariées corrigées $\hat{H}_1^{M, \text{bc}}, \dots, \hat{H}_M^{M, \text{bc}}$
- Statistiques $\hat{\delta}_{m, m'} = \hat{H}_{m'}^{M, \text{bc}} - \hat{H}_m^{M, \text{bc}}$


Test pour $H_m = H_{m'}$

• Formulation :

- $M(M - 1)/2$ hypothèses : $H_m = H_{m'}$, $1 \leq m < m' \leq M$
- Estimées multivariées corrigées $\hat{H}_1^{M, \text{bc}}, \dots, \hat{H}_M^{M, \text{bc}}$
- Statistiques $\hat{\delta}_{m, m'} = \hat{H}_{m'}^{M, \text{bc}} - \hat{H}_m^{M, \text{bc}}$

• Distribution de $\hat{\delta}_{m, m'}$:

- approximativement gaussienne en taille finie
- centrée sous $H_m = H_{m'}$



Test pour $H_m = H_{m'}$

• Formulation :

- $M(M - 1)/2$ hypothèses : $H_m = H_{m'}$, $1 \leq m < m' \leq M$
- Estimées multivariées corrigées $\hat{H}_1^{M, \text{bc}}, \dots, \hat{H}_M^{M, \text{bc}}$
- Statistiques $\hat{\delta}_{m, m'} = \hat{H}_{m'}^{M, \text{bc}} - \hat{H}_m^{M, \text{bc}}$


• Distribution de $\hat{\delta}_{m, m'}$:

- approximativement gaussienne en taille finie
- centrée sous $H_m = H_{m'}$

• p-valeurs :

$$p_{m, m'} = 2 \left(1 - F \left(\frac{|\hat{\delta}_{m, m'}|}{\sigma_{m, m'}} \right) \right)$$

F : fonction de répartition de la loi gaussienne standard



Test pour $H_m = H_{m'}$

• Formulation :

- $M(M - 1)/2$ hypothèses : $H_m = H_{m'}$, $1 \leq m < m' \leq M$
- Estimées multivariées corrigées $\hat{H}_1^{M, \text{bc}}, \dots, \hat{H}_M^{M, \text{bc}}$
- Statistiques $\hat{\delta}_{m, m'} = \hat{H}_{m'}^{M, \text{bc}} - \hat{H}_m^{M, \text{bc}}$


• Distribution de $\hat{\delta}_{m, m'}$:

- approximativement gaussienne en taille finie
- centrée sous $H_m = H_{m'}$

• p-valeurs :

$$p_{m, m'} = 2 \left(1 - F \left(\frac{|\hat{\delta}_{m, m'}|}{\sigma_{m, m'}} \right) \right)$$


F : fonction de répartition de la loi gaussienne standard



⚠ Une seule observation $\Rightarrow \sigma_{m, m'}$ inconnu
 \rightarrow estimation de $\sigma_{m, m'}$ par bootstrap


Ré-échantillonnage par bloc bootstrap temps-échelle multivarié

[Wendt et al., 2007; 2018]




Ré-échantillonnage par bloc bootstrap temps-échelle multivarié

[Wendt et al., 2007; 2018]





Ré-échantillonnage par bloc bootstrap temps-échelle multivarié

[Wendt et al., 2007; 2018]





Ré-échantillonnage par bloc bootstrap temps-échelle multivarié

[Wendt et al., 2007; 2018]




Ré-échantillonnage par bloc bootstrap temps-échelle multivarié

[Wendt et al., 2007; 2018]




Ré-échantillonnage par bloc bootstrap temps-échelle multivarié

[Wendt et al., 2007; 2018]




Ré-échantillonnage par bloc bootstrap temps-échelle multivarié

[Wendt et al., 2007; 2018]




R ré-échantillons d'ondelettes
 $D^{*(r)} = (D_1^{*(r)}, \dots, D_M^{*(r)})$




Ré-échantillonnage par bloc bootstrap temps-échelle multivarié

[Wendt et al., 2007; 2018]




R ré-échantillons d'ondelettes
 $D^{*(r)} = (D_1^{*(r)}, \dots, D_M^{*(r)})$
 \Downarrow
 R estimées bootstrap
 $\hat{H}^{*(r)} = (\hat{H}_1^{*(r)}, \dots, \hat{H}_M^{*(r)})$



Ré-échantillonnage par bloc bootstrap temps-échelle multivarié

[Wendt et al., 2007; 2018]

 R ré-échantillons d'ondelettes


$$D^{*(r)} = (D_1^{*(r)}, \dots, D_M^{*(r)})$$

 R estimées bootstrap

$$\hat{H}^{*(r)} = (\hat{H}_1^{*(r)}, \dots, \hat{H}_M^{*(r)})$$


 R statistiques de test bootstrap

$$\hat{\delta}_{m,m'}^{*(r)} = \hat{H}_{m'}^{*(r)} - \hat{H}_m^{*(r)}$$



Ré-échantillonnage par bloc bootstrap temps-échelle multivarié

[Wendt et al., 2007; 2018]

 R ré-échantillons d'ondelettes

$$D^{*(r)} = (D_1^{*(r)}, \dots, D_M^{*(r)})$$

↓

 R estimées bootstrap

$$\hat{H}^{*(r)} = (\hat{H}_1^{*(r)}, \dots, \hat{H}_M^{*(r)})$$

↓

 R statistiques de test bootstrap

$$\hat{\delta}_{m,m'}^{*(r)} = \hat{H}_{m'}^{*(r)} - \hat{H}_m^{*(r)}$$


↓

Estimées de paramètre de test

$$\hat{\sigma}_{m,m'}^* = \sqrt{\text{Var}^*(\hat{\delta}_{m,m'}^*)}$$

Ré-échantillonnage par bloc bootstrap temps-échelle multivarié

[Wendt et al., 2007; 2018]

 R ré-échantillons d'ondelettes

$$D^{*(r)} = (D_1^{*(r)}, \dots, D_M^{*(r)})$$

↓

 R estimées bootstrap

$$\hat{H}^{*(r)} = (\hat{H}_1^{*(r)}, \dots, \hat{H}_M^{*(r)})$$

↓

 R statistiques de test bootstrap

$$\hat{\delta}_{m,m'}^{*(r)} = \hat{H}_{m'}^{*(r)} - \hat{H}_m^{*(r)}$$

↓

Estimées de paramètre de test


$$\hat{\sigma}_{m,m'}^* = \sqrt{\text{Var}^*(\hat{\delta}_{m,m'}^*)}$$

↓

p-valeurs bootstrap

$$\hat{p}_{m,m'}^*$$

Organigramme de la procédure de test



Validation de la procédure bootstrap

Simulations : 1000 réalisations, $M = 6$, $N = 2^{16}$

$$\underline{H} = (0.8, 0.8, 0.8, 0.8, 0.8, 0.8)$$


Estimation de $\sigma_{m,m'}$ par bootstrap
 (Moyenne de Monte Carlo \pm intervalle de confiance à 95%)

$\times 10^2$	2	3	4	5	6	$m' \diagup m$
$\sigma_{m,m'}$	7.81	7.63	7.59	7.35	7.48	1
$\hat{\sigma}_{m,m'}^*$	7.59	7.51	7.42	7.50	7.65	
	± 0.74	± 0.76	± 0.77	± 0.77	± 0.80	
$\sigma_{m,m'}$		6.83	6.84	6.86	7.00	2
$\hat{\sigma}_{m,m'}^*$		6.54	6.70	6.82	6.98	
		± 0.57	± 0.62	± 0.65	± 0.71	
$\sigma_{m,m'}$			5.82	6.36	6.43	3
$\hat{\sigma}_{m,m'}^*$			5.63	6.19	6.38	
			± 0.53	± 0.55	± 0.62	
$\sigma_{m,m'}$				5.73	6.18	4
$\hat{\sigma}_{m,m'}^*$				5.47	5.89	
				± 0.49	± 0.58	
$\sigma_{m,m'}$					5.45	5
$\hat{\sigma}_{m,m'}^*$					5.39	
					± 0.56	

→ Reproduction de la distribution $\hat{\delta}_{m,m'}$ sous $H_m = H'_m$

Validation de la procédure de test

Simulations : 1000 réalisations, $M = 6$, $N = 2^{16}$



$\hat{p}_{m,m'}^*$ uniforme
sous $H_m = H_{m'}$

$$\underline{H} = (0.8, 0.8, 0.8, 0.8, 0.8, 0.8)$$

Validation de la procédure bootstrap

Simulations : 1000 réalisations, $M = 6, N = 2^{16}$

$$\underline{H} = (0.4, 0.4, 0.6, 0.6, 0.8, 0.8)$$


Estimation de $\sigma_{m,m'}$ par bootstrap
 (Moyenne de Monte Carlo \pm intervalle de confiance à 95%)

$\times 10^2$	2	3	4	5	6	$m' \diagup m$
$\sigma_{m,m'}$	6.32	7.95	7.56	7.39	7.27	1
$\hat{\sigma}_{m,m'}^*$	6.83 ± 0.77	7.82 ± 0.86	7.73 ± 0.83	7.65 ± 0.82	7.69 ± 0.82	1
$\sigma_{m,m'}$		7.36	7.20	7.08	6.87	2
$\hat{\sigma}_{m,m'}^*$		7.11 ± 0.79	6.85 ± 0.73	6.79 ± 0.77	6.65 ± 0.74	2
$\sigma_{m,m'}$			7.12	7.38	7.23	3
$\hat{\sigma}_{m,m'}^*$			6.99 ± 0.75	7.18 ± 0.84	7.11 ± 0.83	3
$\sigma_{m,m'}$				7.20	7.03	4
$\hat{\sigma}_{m,m'}^*$				6.78 ± 0.75	6.67 ± 0.79	4
$\sigma_{m,m'}$					6.94	5
$\hat{\sigma}_{m,m'}^*$					6.39 ± 0.70	5

→ Sous $H_m \neq H'_m$, reproduction de la distribution $\hat{\sigma}_{m,m'}$ sous $H_m = H'_m$

Puissance du test

Simulations : 1000 réalisations, $M = 6$, $N = 2^{16}$




$$\underline{H} = (0.4, 0.4, 0.6, 0.6, 0.8, 0.8)$$

$\hat{p}_{m,m'}^*$ uniforme
sous $H_m = H_{m'}$

$\hat{p}_{m,m'}^*$ s'écarte de la
distribution uniforme
avec $H_{m'} - H_m \neq 0$


Stratégie de partitionnement par graphe

- Graphe : nœuds H_m , matrice de similarité $\mathcal{S} = (\hat{p}_{m,m'}^*)_{m,m'}$



Stratégie de partitionnement par graphe

- Graphe : nœuds H_m , matrice de similarité $\mathcal{S} = (\hat{p}_{m,m'}^*)_{m,m'}$




Stratégie de partitionnement par graphe

- Graphe : nœuds H_m , matrice de similarité $\mathcal{S} = (\hat{p}_{m,m'}^*)_{m,m'}$
- Partitionnement spectral [Filippone et al., 2008]

- Laplacien $\mathcal{L}_{rw} = D^{-1}(D - \mathcal{S})$

Matrice des degrées (diagonale) D : $D_{m,m} = \sum_{m'=1}^M \mathcal{S}_{m,m'}$




Stratégie de partitionnement par graphe

- Graphe : nœuds H_m , matrice de similarité $\mathcal{S} = (\hat{p}_{m,m'}^*)_{m,m'}$
- Partitionnement spectral [Filippone et al., 2008]
 - Laplacien $\mathcal{L}_{rw} = D^{-1}(D - \mathcal{S})$

Matrice des degrés (diagonale) D : $D_{m,m} = \sum_{m'=1}^M \mathcal{S}_{m,m'}$


$$\begin{bmatrix} \varphi_1 & 0 & \cdots & \cdots & 0 \\ 0 & \varphi_2 & \cdots & \cdots & 0 \\ 0 & 0 & \ddots & & \vdots \\ \vdots & \vdots & & \ddots & 0 \\ 0 & 0 & \cdots & 0 & \varphi_M \end{bmatrix} V^{-1}$$

- Décomposition spectrale : $\mathcal{L}_{rw} = V$
- Estimation du nombre de groupes : $\hat{N}_C = \underset{k}{\operatorname{argmax}}(\varphi_{k+1} - \varphi_k)$ [Azran et Ghahramani, 2006]
- Partitionnement : k-moyenne sur $V_1, \dots, V_{\hat{N}_C}$




Stratégie de partitionnement par graphe

$$\underline{H} = (0.4, 0.4, 0.6, 0.6, 0.8, 0.8)$$

Similarité \mathcal{S} 

$$\underline{H} = (0.4, 0.6, 0.6, 0.6, 0.8, 0.8)$$


Similarité \mathcal{S} 

⚠ Normalisation de $\mathcal{L}_{\text{rw}} \rightarrow H_m$ uniques non détectés

Détection de noeuds isolés

Suppression des H_m uniques avant partitionnement



→ Décisions de rejet de Benjamini-Hochberg :
rejeter $H_m = H_{m'}$ si $\hat{p}_{m,m'}^* < d_\alpha^{(m,m')}$
taux de fausses découvertes : $\alpha = 0.05$




Détection de noeuds isolés

Suppression des H_m uniques avant partitionnement

→ Décisions de rejet de Benjamini-Hochberg :
rejeter $H_m = H_{m'}$ si $\hat{p}_{m,m'}^* < d_{\alpha}^{(m,m')}$
taux de fausses découvertes : $\alpha = 0.05$



Performances d'estimation du nombre de groupes

Simulations : 1000 réalisations, $M = 20$ composantes

$$\underline{H} = (0.7, \dots, 0.7)$$

$$\underline{H} = (0.6, \dots, 0.6, 0.8, \dots, 0.8)$$

$$\underline{H} = (0.5, \dots, 0.5, 0.6, \dots, 0.6, 0.7, \dots, 0.7)$$

$$\underline{H} = (0.4, \dots, 0.4, 0.5, \dots, 0.5, 0.6, \dots, 0.6, 0.7)$$

$$M = 20$$

$$M = 10 + 10$$

$$M = 7 + 7 + 6$$

$$M = 7 + 6 + 6 + 1$$

Performances du partitionnement

NMI: information mutuelle normalisée

(*entropie conjointe des partitions exactes et estimées*)

ARI: indice de Rand ajusté

(*paires d'éléments correctement séparées ou rassemblées*)

Performances (entre 0 et 1)

(Moyenne de Monte Carlo \pm intervalle de confiance à 95%)

		2 partitions	3 partitions	4 partitions
$N = 2^{17}$	NMI	0.99 ± 0.00	0.85 ± 0.01	0.83 ± 0.01
	ARI	0.98 ± 0.01	0.79 ± 0.01	0.75 ± 0.01
$N = 2^{18}$	NMI	0.99 ± 0.00	0.97 ± 0.00	0.95 ± 0.00
	ARI	0.98 ± 0.01	0.96 ± 0.01	0.92 ± 0.01
$N = 2^{19}$	NMI	0.99 ± 0.00	0.99 ± 0.00	0.98 ± 0.00
	ARI	0.98 ± 0.01	0.97 ± 0.01	0.97 ± 0.01

$$\underline{H} = (0.6, \dots, 0.6, 0.8, \dots, 0.8)$$

$$M = 10 + 10$$

$$\underline{H} = (0.5, \dots, 0.5, 0.6, \dots, 0.6, 0.7, \dots, 0.7)$$

$$M = 7 + 7 + 6$$

$$\underline{H} = (0.4, \dots, 0.4, 0.5, \dots, 0.5, 0.6, \dots, 0.6, 0.7)$$

$$M = 7 + 6 + 6 + 1$$

→ efficacité du partitionnement spectral, même à faible N

Gliederung

① Introduction

② Modélisation

③ Estimation


④ Dénombrement et regroupement

⑤ Application biomédicale

Prédiction des crises d'épilepsie : données

Outils prêts pour des données du monde réel:

- Stylométrie : 6 indicateurs → roman original ou traduit ?
- Données physiologiques 4-variées → détection de la somnolence [Lucas et al., EMBC, 2022]
- Prédiction de crises d'épilepsie [Lucas et al., EUSIPCO, 2023]



Base de données



- CHB-MIT Scalp EEG physionet.org/content/chbmit/
- 8 sujets pédiatriques
- 19 canaux échantillonés à 256Hz

Objectif : classification binaire de fenêtres 19-variées de 2 minutes

- **état préictal** : période quelques minutes avant une crise d'épilepsie
- **état interictal** : période loin d'une crise d'épilepsie

Prédiction de crises d'épilepsie : invariance d'échelle


Analyse par patient



⇒ Comportement invariant d'échelle multivarié sur $2^1 - 2^8 = 0.5\text{Hz} - 85\text{Hz}$

Comparaison des distributions des paramètres d'autosimilarité

Fréquences d'analyse 10Hz – 85Hz [Gadhoumi et al., 2015]


⇒ Échelles d'analyse $2^{j_1} = 2^1 - 2^{j_2} = 2^4$ 

- Différences entre distributions **interictales** et **préictales** par patient
 → Différences entre les différents patients

Prédiction des crises d'épilepsie : invariance d'échelle

Test de Wilcoxon :

p-valeurs (interictal contre preictal) pour \hat{H}^U , \hat{H}^M et $\hat{H}^{M,bc}$
 Seuils de Benjamini-Hochberg (comparaison multiple)




→ Différences entre états interictaux et preictaux par patient

- significatives pour tous les patients
- plus significatives avec $\hat{H}^{M,bc}$

Prédiction des crises d'épilepsie : classification

- Classification par patient [Lucas et al., EUSIPCO, 2023]
- Procédure pour chaque patient:




où les $\hat{H}_1, \dots, \hat{H}_M$ sont

- soit les estimées univariées $\hat{H}_1^U, \dots, \hat{H}_M^U$,
- soit les estimées multivariées corrigées $\hat{H}_1^{M,bc}, \dots, \hat{H}_M^{M,bc}$.

- Même procédure avec $M(M + 1)/2$ estimées multivariées classiques $\hat{H}_{m,m'}$

Prédiction des crises d'épilepsie : performances de classification

Courbes ROC avec AUC (aire sous la courbe)



+ M estimées univariées \hat{H}_m^U

Δ $M(M + 1)/2$ estimées multivariées classiques $\hat{H}_{m,m'}$

o M estimées multivariées corrigées $\hat{H}_m^{M,bc}$

$$\hat{H}_m^{M,bc} \sim \hat{H}_{m,m'} \geq \hat{H}_m^U$$

Résultats et perspectives

Résultats

- Estimation de \underline{H} robuste au biais de répulsion
- Tests d'égalité : partitionnement de \underline{H} en paramètres égaux
- Boîte à outils MatLab en ligne : github.com/charlesglucas/ofbm_tools
- Applications biomédicales : procédure de classification

Travaux en cours

- Grande dimension : M grand avec N limité
 - Triple limite : $M \rightarrow +\infty$, $N \rightarrow +\infty$, $2^{j_1}, \dots, 2^{j_2} \rightarrow +\infty$
 - Perte de la normalité multivariée de l'estimateur
 - Nouvelle approche du partitionnement de \underline{H} [Lucas et al., GRETSI, 2023]

Perspectives

- Prise en compte de l'irréversibilité en temps :

$$\{\mathcal{B}_{\underline{H}, \Sigma, W}(t)\}_{t \in \mathbb{R}} \stackrel{fdd}{\neq} \{\mathcal{B}_{\underline{H}, \Sigma, W}(-t)\}_{t \in \mathbb{R}}$$
- Extension à deux dimensions : texture d'images et anisotropie (e.g. imagerie hyperspectrale)

$$\{\mathcal{B}_{\underline{H}, \Sigma, W}(\textcolor{red}{a}^{\textcolor{green}{E}} x)\}_{x \in \mathbb{R}^2} \stackrel{fdd}{=} \{\textcolor{red}{a}^{\underline{H}} \mathcal{B}_{\underline{H}, \Sigma, W}(x)\}_{x \in \mathbb{R}^2}, \quad \forall \textcolor{red}{a} \in \mathbb{R}^2$$

$\textcolor{green}{E}$: matrice 2×2 caractérisant l'anisotropie

Communications

– Estimation

[\[Lucas et al., 2023a\]](#) C-G. Lucas, P. Abry, H. Wendt and G. Didier, Multivariate self-similarity: Multiscale eigen structures for the estimation of Hurst exponents. Soumis.

– Applications

[\[Lucas et al., EMBC, 2022\]](#) C-G. Lucas, P. Abry, H. Wendt and G. Didier, Drowsiness detection from polysomnographic data using multivariate selfsimilarity-based eigen-wavelet analyses, EMBC, Glasgow, Scotland, 2022.

[\[Lucas et al., EUSIPCO, 2023\]](#) C-G. Lucas, P. Abry, H. Wendt and G. Didier, Epileptic seizure prediction from eigen-wavelet multivariate selfsimilarity analysis of multi-channel EEG signals, EUSIPCO, Helsinki, Finland, 2023.

– Dénombrement et regroupement de paramètres égaux

[\[Lucas et al., EUSIPCO, 2021\]](#) C-G. Lucas, P. Abry, H. Wendt and G. Didier, Bootstrap for testing the equality of selfsimilarity exponents across multivariate time series, EUSIPCO, Dublin, Ireland, 2021.

[\[Lucas et al., ICASSP, 2022\]](#) C-G. Lucas, P. Abry, H. Wendt and G. Didier, Counting the number of different scaling exponents in multivariate scale-free dynamics: clustering by bootstrap in the wavelet domain, ICASSP, Singapore, 2022.

[\[Lucas et al., GRETSI, 2022\]](#) C-G. Lucas, P. Abry, H. Wendt and G. Didier, Multivariate time-scale bootstrap for testing the equality of selfsimilarity parameters, GRETSI, Nancy, France, 2022.

[\[Lucas et al., 2023b\]](#) C-G. Lucas, P. Abry, H. Wendt and G. Didier, Multivariate self-similarity parameter counting: Spectral clustering using wavelet-domain bootstrap. En cours d'écriture.

– Grande dimension

[\[Lucas et al., GRETSI, 2023\]](#) C-G. Lucas, P. Abry, H. Wendt, G. Didier and O. Orejola, Bootstrap based test for the unimodality of estimated Hurst exponents. Performance assessment in a high-dimensional analysis setting, GRETSI, Grenoble, France, 2023.



POUR VOTRE ATTENTION !

Lois de puissance des valeurs propres

Idée de la démonstration [Abry et al., 2018a; 2018b]

$\mathcal{B}_{\underline{H}, \Sigma, W}$ autosimilaire $\Rightarrow S(a(N)2^j) \xrightarrow{\mathbb{P}} a(N)^{(\underline{H} + \frac{1}{2}\mathbb{I})} S(2^j) a(N)^{(\underline{H}^\top + \frac{1}{2}\mathbb{I})}$

avec $a(N)^{\underline{H}} = a(N)^{W \text{diag}(\underline{H}) W^{-1}}$

$$= W \begin{bmatrix} a(N)^{\underline{H}_1} & 0 & \cdots & \cdots & 0 \\ 0 & a(N)^{\underline{H}_2} & \cdots & \cdots & 0 \\ 0 & 0 & \ddots & & \vdots \\ \vdots & \vdots & & \ddots & 0 \\ 0 & 0 & \cdots & 0 & a(N)^{\underline{H}_M} \end{bmatrix} W^{-1}$$

→ Valeurs propres $\hat{\lambda}_m(2^j)$ de $S(2^j)$ asymptotiquement bornées :

$$\hat{\lambda}_m(2^j) \xrightarrow{\mathbb{P}} l_m \text{ avec } 0 < l_m \leq B_m$$

→ Encadrement des valeurs propres $\hat{\lambda}_m(a(N)2^j)$ de $S(a(N)2^j)$ par les valeurs propres de $a(N)^{(\underline{H} + \frac{1}{2}\mathbb{I})} a(N)^{(\underline{H}^\top + \frac{1}{2}\mathbb{I})}$, i.e. par les $a(N)^{2\underline{H}_m + 1}$

$$\rightarrow \hat{\lambda}_m(a(N)2^j) \propto a(N)^{2\underline{H}_m + 1}$$

Étude des performances d'estimation empiriques

Simulations de Monte Carlo :

- 1000 réalisations
- $M = 6$ composantes
- Tailles d'échantillon $N \in \{2^{13}, \dots, 2^{18}\}$
- 2 différent vecteurs \underline{H} :
 - $H_1 = \dots = H_M = 0.7$
 - $H_1 \neq \dots \neq H_M$: $\underline{H} = (0.4, 0.5, 0.6, 0.65, 0.7, 0.8)$
- Matrice de mélange aléatoire non orthonormale $W \neq \mathbb{I}$ ou $W = \mathbb{I}$
- Corrélation $\Sigma \neq \mathbb{I}$ avec $\Sigma_{m,m'} = 0.7^{|m'-m|}$, $1 \leq m \leq m' \leq M$

Analyse en ondelettes :

- Ondelette mère : Daubechies2
- Régressions linéaires de $2^{j_1} = a(N)2^6$ à $2^{j_2} = a(N)2^9$
avec $\log_2 a(N) = \lfloor \beta \log_2 N/N_0 \rfloor$, $\beta = 0.9$, $N_0 = 2^{13}$


Performances d'estimation

$$W \neq \mathbb{I}$$


$$H_1 \neq \dots \neq H_M$$

- + estimation univariée \hat{H}^U
- Δ estimation multivariée \hat{H}^M
- o estimation multivariée corrigée $\hat{H}^{M, bc}$

Ondelette mère : Daubechies2



Ondelette mère : Daubechies10




Performances d'estimation

$$W \neq \mathbb{I}$$


$$H_1 = \dots = H_M$$

- + estimation univariée \hat{H}^U
- Δ estimation multivariée \hat{H}^M
- o estimation multivariée corrigée $\hat{H}^{M, bc}$

Ondelette mère : Daubechies2



Ondelette mère : Daubechies10




Performances d'estimation

$$W = \mathbb{I}$$


$$H_1 \neq \dots \neq H_M$$

- + estimation univariée \hat{H}^U
- Δ estimation multivariée \hat{H}^M
- o estimation multivariée corrigée $\hat{H}^{M, bc}$

Ondelette mère : Daubechies2



Ondelette mère : Daubechies10




Performances d'estimation

$$W = \mathbb{I}$$


$$H_1 = \dots = H_M$$

+ estimation univariée \hat{H}^U
 Δ estimation multivariée \hat{H}^M
 \circ estimation multivariée corrigée $\hat{H}^{M, bc}$

Ondelette mère : Daubechies2



Ondelette mère : Daubechies10



Performances d'estimation

$$W \neq \mathbb{I}$$


$$H_1 \neq \dots \neq H_M$$

+ estimation univariée \hat{H}^U


Δ estimation multivariée \hat{H}^M

o estimation multivariée corrigée $\hat{H}^{M, bc}$

Norme spectrale :



Norme de Frobenius :




Performances d'estimation

$$W \neq \mathbb{I}$$


$$H_1 = \dots = H_M$$

- + estimation univariée \hat{H}^U
- Δ estimation multivariée \hat{H}^M
- o estimation multivariée corrigée $\hat{H}^{M, bc}$

Norme spectrale :



Norme de Frobenius :



Performances d'estimation


$$W = \mathbb{I}$$

+ estimation univariée \hat{H}^U


Δ estimation multivariée \hat{H}^M

o estimation multivariée corrigée $\hat{H}^{M, bc}$

Norme spectrale :



Norme de Frobenius :




Performances d'estimation

$$W = \mathbb{I}$$


$$H_1 = \dots = H_M$$

- + estimation univariée \hat{H}^U
 Δ estimation multivariée \hat{H}^M
 \circ estimation multivariée corrigée $\hat{H}^{M, bc}$

Norme spectrale :



Norme de Frobenius :




Corrélation des estimateurs

$$W \neq \mathbb{I}$$

$$H_1 = \dots = H_M$$

+ estimation univariée \hat{H}^U
 Δ estimation multivariée \hat{H}^M
 o estimation multivariée corrigée $\hat{H}^{M,bc}$




→ Quasi-décorrélation de $\hat{H}^{M,bc}$ et \hat{H}^M , même pour N faible

Corrélation des estimateurs

$$W = \mathbb{I}$$

$$H_1 = \dots = H_M$$

+ estimation univariée \hat{H}^U
 Δ estimation multivariée \hat{H}^M
 o estimation multivariée corrigée $\hat{H}^{M,bc}$




→ Quasi-décorrélation de $\hat{H}^{M,bc}$ et \hat{H}^M , même pour N faible


Variance des estimateurs

$$V_N = 2(\log_2 e)^2 \sum_{j=j_1}^{j_2} \frac{w_j^2}{n_{a,j}}$$

$W \neq \mathbb{I}$
 $H_1 \neq \dots \neq H_M$




$W \neq \mathbb{I}$
 $H_1 = \dots = H_M$




Variance des estimateurs

$$V_N = 2(\log_2 e)^2 \sum_{j=j_1}^{j_2} \frac{w_j^2}{n_{a,j}}$$

$W = \mathbb{I}$
 $H_1 \neq \dots \neq H_M$



$W = \mathbb{I}$
 $H_1 = \dots = H_M$



Étude des performances de partitionnement empiriques

Analyse en ondelettes :

- Ondelette mère ψ_0 : Daubechies3
- Régression linéaire de :
 - 2^8 à 2^{11} pour $M = 6$
 - 2^7 à 2^{10} pour $M = 20$
- Mélange W inversible et non orthonormal aléatoire
- $\Sigma = \text{diag}(\sigma_1, \dots, \sigma_M) \rho \text{diag}(\sigma_1, \dots, \sigma_M)^T$
 - $\rho = 0.5$ et $\sigma_m = 1$ pour $M = 6$
 - $\rho = 0.5$ et $\sigma_m = 2^m$ pour $M = 20$





Bootstrap :

- $R = 500$ ré-échantillons
- Taille des blocs N_B = taille du support de $\psi_0 = 6$

Test pour $H_1 = \dots = H_M$: statistique et puissance

Statistique : $T^* = (\hat{H}^{\text{M,bc}} - \langle \hat{H}_m^{\text{M,bc}} \rangle_m)^\top \left(\hat{\Sigma}_{\hat{H}}^* \right)^{-1} (\hat{H}^{\text{M,bc}} - \langle \hat{H}_m^{\text{M,bc}} \rangle_m)$

→ sous $H_1 = \dots = H_M$, χ^2 à $M - 1$ degrés de liberté pour N grand




$$\underline{H} = 0.5 + (0, \dots, 0, \Delta H, \dots, \Delta H, 2\Delta H, \dots, 2\Delta H, 3\Delta H, \dots, 3\Delta H)$$

$$M \equiv M_1 + M_2 + M_3 + M_4$$

Test pour $H_m = H_{m+1}$: procédure

- Formulation :
 - $M - 1$ hypothèse : $H_m = H_{m+1}$, $1 \leq m \leq M$
 - Tri des estimées corrigées : $\hat{H}_{\tau(1)} \leq \dots \leq \hat{H}_{\tau(M)}$
 - Statistiques : $\tilde{\delta}_m = \hat{H}_{\tau(m+1)} - \hat{H}_{\tau(m)}$
- Distribution approximative :
 - $\tilde{\delta}_m$ normale repliée pour N grand et M petit
 - $\tilde{\delta}_m$ demi-normale $\mathcal{FN}(0, \tilde{\sigma}_m)$ pour N grand et M petit sous $H_m = H_{m+1}$
- p-valeurs : $\tilde{p}_m = 1 - F_{\mathcal{FN}(0, \tilde{\sigma}_m)}(\tilde{\delta}_m)$
- Décisions $d_{\alpha}^{(m)}$: procédure de Benjamini-Hochberg sur les p-valeurs \tilde{p}_m
- Partitionnement :



→ Estimation de $\tilde{\sigma}_m$ par bootstrap

Test pour $H_m = H_{m+1}$: estimation des paramètres

Estimation du paramètre $\tilde{\sigma}_m$ de la loi demi-normale par bootstrap :

- Reproduction de $H_1 = \dots = H_M$ [Lucas et al., ICASSP, 2022] :


$$\delta_m^{*(r)} = \bar{H}_{\tau^{*(r)}(m+1)}^{*(r)} - \bar{H}_{\tau^{*(r)}(m)}^{*(r)}, \quad \bar{H}^{*(r)} = \hat{H}^{*(r)} - \langle \hat{H}^{*(r)} \rangle_r$$


⇒ estimer le paramètre $\tilde{\sigma}_m^*$ de loi demi-normale

- Reproduction de l'hypothèse observée [Lucas et al., GRETSI, 2022] :

$$\tilde{\delta}_m^{*(r)} = \hat{H}_{\tau^{*(r)}(m+1)}^{*(r)} - \hat{H}_{\tau^{*(r)}(m)}^{*(r)}$$


⇒ estimer le paramètre $\tilde{\sigma}_m^*$ de loi normale repliée



Test pour $H_m = H_{m+1}$: performancesReproduction de $H_1 = \dots = H_M$ Diagrammes quantile-quantile
 \bar{p}_m^* contre distribution uniforme

Test pour $H_m = H_{m+1}$: performances

Reproduction de l'hypothèse observée

Diagrammes quantile-quantile
 \tilde{p}_m^* contre distribution uniforme

Partitionnement : comparaison de laplaciens





Partitionnement spectral sur

- Laplacien normalisé $\mathcal{L}_{rw} = D^{-1}(D - \mathcal{S})$

Désavantage : ne permet pas d'identifier des nœuds isolés

- Laplacien combinatoire $\mathcal{L} = D - W$

Désavantage : moins adapté que \mathcal{L}_{rw} pour la convergence
 [Von Luxburg, 2008; Sarkar, 2015]



$$\underline{H} = (0.4, 0.4, 0.6, 0.6, 0.8, 0.8)$$

Partitionnement : comparaison de laplaciens





Partitionnement spectral sur

- Laplacien normalisé $\mathcal{L}_{rw} = D^{-1}(D - \mathcal{S})$

Désavantage : ne permet pas d'identifier des nœuds isolés

- Laplacien combinatoire $\mathcal{L} = D - W$

Désavantage : moins adapté que \mathcal{L}_{rw} pour la convergence
 [Von Luxburg, 2008; Sarkar, 2015]



$$\underline{H} = (0.4, 0.6, 0.6, 0.6, 0.8, 0.8)$$

Partitionnement : comparaison de laplaciens





Partitionnement spectral sur

- Laplacien normalisé $\mathcal{L}_{rw} = D^{-1}(D - \mathcal{S})$

Désavantage : ne permet pas d'identifier des nœuds isolés

- Laplacien combinatoire $\mathcal{L} = D - W$

Désavantage : moins adapté que \mathcal{L}_{rw} pour la convergence
 [Von Luxburg, 2008; Sarkar, 2015]



$$\underline{H} = (0.4, \dots, 0.4, 0.6, \dots, 0.6, 0.8, \dots, 0.8), \quad M = 6 + 7 + 7$$

Partitionnement : comparaison de laplaciens





Partitionnement spectral sur

- Laplacien normalisé $\mathcal{L}_{rw} = D^{-1}(D - \mathcal{S})$

Désavantage : ne permet pas d'identifier des nœuds isolés

- Laplacien combinatoire $\mathcal{L} = D - W$

Désavantage : moins adapté que \mathcal{L}_{rw} pour la convergence
 [Von Luxburg, 2008; Sarkar, 2015]



$$\underline{H} = (0.4, \dots, 0.4, 0.6, \dots, 0.6, 0.8), \quad M = 9 + 10 + 1$$

Partitionnement : Indice de Rand ajusté

ARI, Adjusted Rand Index

2 partitions de $\mathcal{V} = \{1, \dots, M\}$: $U = \{U_1, U_2, \dots, U_R\}$, $V = \{V_1, V_2, \dots, V_C\}$.

$$RI = (a + b) / \binom{M}{2}$$

- a : nombre de paires d'éléments de \mathcal{V} dans le même sous-sensemble à la fois dans V and dans U
- b : nombre de paires d'éléments de \mathcal{V} dans différents sous-sensemble à la fois dans V and dans U

$$ARI = \frac{RI - ERI}{\max(RI) - ERI}$$

Partitionnement : Information mutuelle normalisée

NMI, Normalized Mutual Information

2 partitions de $\mathcal{V} = \{1, \dots, M\}$: $U = \{U_1, U_2, \dots, U_R\}$, $V = \{V_1, V_2, \dots, V_C\}$.

$$NMI = \frac{H(U) + H(V) - H(U, V)}{\sqrt{H(U)H(V)}}$$

avec

$$H(U) = - \sum_i q_{i,.} \log_2(q_{i,.})$$

$$H(V) = - \sum_j q_{.,j} \log_2(q_{.,j})$$

$$H(U, V) = - \sum_{i,j} q_{i,j} \log_2(q_{i,j})$$

with:

- $q_{i,j} = P(U_i \cap V_j)$: proportion d'éléments à la fois dans U_i et V_j
- $q_{i,.} = P(U_i)$: proportion d'éléments dans U_i
- $q_{.,j} = P(V_j)$: proportion d'éléments dans V_j





Prédiction de crises d'épilepsie : pré-traitement et analyse des données

- Univarié : $N/2^j = n_j \gg 8$
- Multivarié : $N/2^j = n_j \gg 4M$ ($\Rightarrow S(2^j)$ de rang plein)
 $\rightarrow M = 19 \Rightarrow \simeq 2^6 \Rightarrow N \gg 2^{j+6}$
 \rightarrow Lois de puissance de 2^1 à $2^8 \Rightarrow N > 2^{8+6} = 2^{14}$
 \rightarrow Fréquence d'échantillonnage $f_0 = 256\text{Hz} \Rightarrow$ fenêtres de $2^{15}/256 \simeq 2\text{mn}$

Ondelette mère : Daubechies2

Bootstrap : $R = 500$ ré-échantillons, taille des blocs $N_B = 4$


Prédiction de crises d'épilepsie : partitionnement




Stylométrie : romans VO/VT

Romans français : 20 en version originale (VO), 25 en version traduite (VT)

Taille des romans (nombre de phrases) : de 971 à 14 587, en moyenne 6 157




Stylométrie : analyse 6-variée



Corrélations	lettres	virgules	mots	et	lemme Dire	adv "ment"
lettres	1	0.67	0.98	0.45	0.11	0.14
virgules	0.67	1	0.66	0.20	0.11	0.05
mots	0.98	0.66	1	0.46	0.13	0.10
et	0.45	0.20	0.46	1	0.02	0.07
lemme Dire	0.11	0.11	0.13	0.02	1	0.04
adv 'ment'	0.14	0.05	0.10	0.07	0.04	1

Objectif : comparaison entre VO et VT par autosimilarité multivariée

Stylométrie : analyse 6-variée





Corrélations	lettres	virgules	mots	et	lemme Say	adv 'ly'
lettres	1	0.51	0.97	0.39	-0.01	0.21
virgules	0.51	1	0.49	0.14	0.23	0.16
mots	0.97	0.49	1	0.39	0.00	0.17
and	0.39	0.14	0.39	1	-0.06	0.04
lemme Say	-0.01	0.23	0.00	-0.06	1	0.02
adv 'ly'	0.21	0.16	0.17	0.04	0.02	1

Objectif : comparaison entre VO et VT par autosimilarité multivariée



Stylométrie : analyse 6-variée

Analyse en ondelettes sur les échelles 2^3 à $2^{\log_2(N)-4}$

Romans francophones : lettres, virgules, mots, 'et', lemme Dire, adverbe 'ment'







Romans anglophones : lettres, virgules, mots, 'and', lemme Say, adverbe 'ly'



Stylométrie : analyse 6-variée

Analyse en ondelettes sur les échelles 2^3 à $2^{\log_2(N)-4}$





Romans francophones : lettres, virgules, mots, 'et', lemme Dire, adverbe 'ment'







Stylométrie : analyse 6-variée

Analyse en ondelettes sur les échelles 2^3 à $2^{\log_2(N)-4}$

Romans anglophones : lettres, virgules, mots, 'and', lemme Say, adverbe 'ly'



Partitionnement par graphe des romans



Régime asymptotique de grande dimension

Dans certaines applications : M grand avec N limité

- Magnetoencephalographie (MEG): $M \sim 100$
- Imagerie par résonance magnétique fonctionnelle (IRMs): $M \sim 10000$

Cadre asymptotique

Triple limite :

- $N \rightarrow +\infty$
- $2^{j_1}, \dots, 2^{j_2} \rightarrow +\infty$
- $M \rightarrow +\infty$

vitesse contrôlée par

$$\frac{M}{N/2^{j_1}} \rightarrow c_1 \in [0, 1]$$

⋮

$$\frac{M}{N/2^{j_2}} \rightarrow c_J \in [0, 1]$$




Étude numérique : 100 réalisations, $\Sigma = \mathbb{I}$, W orthonormale aléatoire

Enjeux de la grande dimension




$$\underline{H} = (0.6, \dots, 0.6, 0.8, \dots, 0.8), \quad M = M/2 + M/2$$

Diagramme quantile-quantile de \hat{H} contre χ^2 à M degrés de liberté

$$\frac{M}{N/2^{j/2}} = \frac{1}{8}$$



$$- \frac{M}{N/2^{j/2}} = \frac{1}{4}$$




Enjeux de la grande dimension


$$\underline{H} = (0.6, \dots, 0.6, 0.8, \dots, 0.8), \quad M = M/2 + M/2$$

Matrices de similarité \mathcal{S} pour $\frac{M}{N/2^{j_2}} = \frac{1}{8}$


$$N = 2^{11}, M = 2^4, j_1 = 2, j_2 = 4$$



$$N = 2^{13}, M = 2^5, j_1 = 3, j_2 = 5$$




$$N = 2^{15}, M = 2^6, j_1 = 4, j_2 = 6$$




Matrices de similarité \mathcal{S} pour $\frac{M}{N/2^{j_2}} = \frac{1}{4}$


$$N = 2^{10}, M = 2^4, j_1 = 2, j_2 = 4$$



$$N = 2^{12}, M = 2^5, j_1 = 3, j_2 = 5$$



$$N = 2^{14}, M = 2^6, j_1 = 4, j_2 = 6$$






Enjeux de la grande dimension




$$\underline{H} = (0.6, \dots, 0.6, 0.8, \dots, 0.8), \quad M = M/2 + M/2$$

Histogramme des nombres de partitions estimés par partitionnement spectral

$$\frac{M}{N/2^{j_2}} = \frac{1}{8}$$












$$\frac{M}{N/2^{j_2}} = \frac{1}{4}$$



⇒ Surestimation

Comportement de l'estimateur en grande dimension

$$\underline{H} = (\underbrace{H_1, \dots, H_1}_{p_1}, \underbrace{H_2, \dots, H_2}_{p_2}, \dots, \dots, \underbrace{H_{N_C}, \dots, H_{N_C}}_{p_{N_C}})$$

Histogrammes des \hat{H}_m au travers de $m = 1, \dots, M$ et 100 réalisations

Proportions p_i de valeurs H_i dans \underline{H} égales
 avec $\Delta H = H_{i+1} - H_i$

Conjecture
 Nombre N_C de valeurs
 différentes H_i dans \underline{H}

\Leftrightarrow
 Nombre de modes dans \hat{H}
 [Orejola et al., 2022]



Tests de multimodalité sur \hat{H}

Dénombrement en grande dimension

→ $H_1 = \dots = H_M$? ⇒ Test d'unimodalité sur \hat{H} [Lucas et al., GRETSI, 2023]

→ Estimation du nombre N_C de paramètres différents dans \hat{H} :

- Tester $\mathcal{H}_0^{(k)}$: "au plus $k \geq 2$ modes dans \hat{H} " [Silverman, 1981]
- Estimée de \hat{N}_C : plus petit k telle $\mathcal{H}_0^{(k)}$ non rejetée
- Histogrammes de \hat{N}_C sur 100 réalisations :

